

[T02] Tugas Individu - Menghapus Duplikasi dan Menangani Missing Value

Deskripsi Singkat

Kerjakan tugas mandiri untuk memahami dan menerapkan **teknik dasar pembersihan data (data cleaning)** menggunakan **NumPy dan Pandas**.

Fokus utama tugas ini adalah:

1. Mengidentifikasi dan **menghapus data duplikat**,
2. Mendeteksi dan **menangani data hilang (missing values)** menggunakan berbagai strategi pengisian,
3. Menulis laporan singkat bergaya **IEEE conference** di Overleaf mengenai hasil dan analisis pembersihan data.
4. Tautan template: <https://www.overleaf.com/latex/templates/ieee-conference-template/grfzhnscsfqn>

Dataset

Gunakan dataset dari repo dosen:

https://github.com/virgantara/machine-learning-course/blob/master/week05/data/data_kotor.csv

Aturan & Batasan

- **Gunakan hanya:** numpy, pandas
- **Tidak boleh** memakai library tambahan (e.g., sklearn, missingno, fancyimpute, dll)
- Kode harus **reproducible**, rapi, dan diberi komentar.
- Simpan hasil *cleaning* dalam file CSV baru:
student_scores_cleaned.csv
- Laporan wajib dibuat dengan **template IEEE Conference (Overleaf)**.
- **Penamaan file tidak sama dengan format, nilai = 0**
- **Terlambat mengumpulkan, nilai = 0**

Output yang Dikumpulkan

1. **Kode Python:**
T02_NIM_cleaning.py
2. **Laporan PDF IEEE-style:**
Minimal 3 halaman berisi:
 - Abstract
 - Introduction
 - Methods (deteksi & penghapusan duplikasi, teknik imputation)
 - Results (tabel ringkasan & cuplikan hasil cleaning)
 - Discussion (analisis dampak cleaning)
 - Conclusion
3. CSV hasil bersih: student_scores_cleaned.csv
4. Penamaan laporan, T02_NIM_Laporan.pdf
5. **Taruh ketiga file tersebut dalam satu file zip dengan format T02_NIM.zip**

Spesifikasi Eksperimen:

1. Deteksi dan Penghapusan Duplikasi
2. Menangani Missing Values
3. Validasi Data

Struktur Laporan (IEEE Format)

| Bagian | Isi yang Diharapkan |
|---------------------|--|
| Abstract | Ringkasan tujuan cleaning dan hasil utama |
| Introduction | Pentingnya data cleaning dalam ML |
| Methods | Langkah-langkah duplikasi dan imputasi |
| Results | Jumlah data sebelum/sesudah cleaning, tabel perbandingan |
| Discussion | Analisis pengaruh pembersihan data terhadap kualitas dataset |
| Conclusion | Ringkasan hasil dan rekomendasi |

Rubrik Penilaian Tugas Individu [T02]

| Aspek | Deskripsi | Kriteria Penilaian | Bobot (%) |
|---|---|--|-----------|
| 1. Implementasi Kode (Cleaning) | Kode mampu menghapus duplikasi, mendeteksi & menangani missing value sesuai metode. | Excellent (90–100): Semua langkah berfungsi, hasil sesuai logika, kode bersih dan terdokumentasi. Good (75–89): Ada kekurangan minor, tapi hasil benar. Fair (60–74): Hanya satu teknik cleaning diterapkan. Poor (<60): Kode error atau tidak sesuai instruksi. | 40 |
| 2. Eksperimen & Hasil (CSV & Output) | File hasil cleaning valid, jumlah data konsisten, perubahan terdokumentasi. | Excellent: Hasil lengkap & benar, file CSV bersih. Good: Minor kesalahan. Fair: Hasil tidak konsisten. Poor: Tidak ada output valid. | 20 |
| 3. Analisis Data Cleaning | Mahasiswa menjelaskan dampak penghapusan duplikasi & imputasi terhadap dataset. | Excellent: Analisis mendalam (mis. perubahan distribusi, potensi bias). Good: Analisis logis tapi singkat. Fair: Hanya menjelaskan langkah tanpa analisis. Poor: Tidak ada pembahasan. | 20 |
| 4. Kualitas Laporan IEEE (LaTeX) | Struktur sesuai IEEE, 4 halaman, bahasa formal, tabel/gambar jelas. | Excellent: Lengkap dan rapi. Good: Struktur benar tapi kurang halus. Fair: Tidak lengkap atau format salah. Poor: Tidak pakai format IEEE. | 15 |
| 5. Kerapihan & Etika Akademik | Penamaan variabel, komentar kode, orisinalitas, gaya penulisan. | Excellent: Kode rapi dan orisinal. Good: Cukup rapi. Fair: Minim komentar. | 5 |

Aspek

Deskripsi

Kriteria Penilaian

**Bobot
(%)**

Poor: Plagiasi.